

Penanganan Laporan Multi-Instansi pada Sistem Klasifikasi Jakarta CRM

Standalone analysis (Deliverable 3)

1 Penanganan Laporan dengan Rute Multi-Instansi pada Sistem Klasifikasi Jakarta CRM

1.1 Kasus Bermasalah dan Posisi Sistem Saat Ini

Sistem klasifikasi multimodal yang dibangun pada penelitian ini mengeluarkan satu instansi prediksi tunggal melalui operasi $\hat{y} = \arg \max_{k \in \{1, \dots, K\}} P(y = k | x)$ dengan $K = 9$, seperti diimplementasikan pada `serve_model.py (idx = int(np.argmax(probs)))`. Pendekatan *single-argmax* ini mengasumsikan bahwa setiap laporan warga memiliki tepat satu instansi pemilik. Asumsi tersebut dilanggar pada kasus-kasus berikut yang ditemukan dalam dataset Jakarta CRM:

- Sebuah laporan memuat *foto satu lokasi* yang menampilkan jalan berlubang *dan* mobil yang parkir liar di trotoar; narasi pelapor menyebutkan kedua isu sekaligus. Rute yang sah: $\{Dinas Bina Marga, Dinas Perhubungan\}$.
- Laporan saluran air mampet di permukiman padat penduduk yang memerlukan koordinasi antara *Dinas Sumber Daya Air* (drainase makro) dan *Kelurahan* (sampah lokal di mulut saluran).
- Laporan pohon tumbang yang menutup ruas jalan, melibatkan *Dinas Pertamanan dan Hutan* dan *Dinas Bina Marga*.

Tsoumakas and Katakis (2007) dan Zhang and Zhou (2014) mendokumentasikan bahwa kasus seperti ini bukan *label noise* yang dapat dibersihkan, melainkan *struktur masalah* yang harus dimodelkan: ruang label yang sah bersifat himpunan (*set-valued*). Dengan demikian sistem perlu direformulasikan dari klasifikasi *multi-class* menjadi klasifikasi *multi-label*.

1.2 Reformulasi Formal Masalah

Misalkan x adalah pasangan citra dan teks laporan, dan $\ell = (lat, lon)$ adalah koordinat GPS yang diambil oleh klien Flutter pada saat pelaporan. Ruang keluaran diubah dari $\hat{y} \in \{1, \dots, K\}$ menjadi himpunan instansi:

$$\hat{Y}(x, \ell) = \{k \in \{1, \dots, K\} : s_k(x, \ell) \geq \tau_k\}, \quad (1)$$

dengan $s_k(x, \ell)$ adalah skor relevansi instansi k terhadap laporan (x, ℓ) dan τ_k adalah ambang yang dikalibrasi secara per-kelas. Ukuran himpunan $|\hat{Y}|$ dapat bernilai 1 (rute tunggal sebagaimana sistem saat ini) atau lebih besar (rute jamak).

1.3 Survei Enam Metode Penanganan

Setiap metode dievaluasi pada empat kriteria: (M) ketepatan matematis, (D) ketersediaan data Jakarta CRM, (C) biaya pelatihan ulang, (G) jaminan formal yang ditawarkan.

Metode 1 — Top-K dengan margin gating

Pertahankan *softmax* 9-kelas yang ada; emisikan dua label jika $P_{(1)} - P_{(2)} < \delta$ (mis. $\delta = 0,10$). Skor $s_k = P(y = k | x)$, ambang dinamis δ menggantikan τ_k . (M) sederhana namun *ad hoc*; (D) tidak butuh data tambahan; (C) nol; (G) tidak ada.

Metode 2 — Binary Relevance (BR)

Latih $K = 9$ klasifikator CatBoost biner independen, masing-masing memprediksi $P(y_k = 1 | x)$. Keluaran: $\hat{Y} = \{k : P(y_k = 1 | x) > \tau_k\}$ (Tsoumakas and Katakis, 2007; Zhang and Zhou, 2014). (M) optimal jika label antar-instansi independen — asumsi yang dilanggar di Jakarta karena *Bina Marga* dan *Perhubungan* berkorelasi pada laporan jalan; (D) butuh *ground-truth* multi-label; (C) $K \times$ pelatihan ulang; (G) tidak ada.

Metode 3 — Classifier Chains (CC)

K klasifikator biner berurutan, di mana kepala ke- k menerima fitur x ditambah keluaran kepala $1, \dots, k-1$, sehingga model dapat menangkap korelasi antar-instansi (Read et al., 2009). (M) lebih kuat daripada BR pada label yang berkorelasi, tetapi sensitif terhadap urutan rantai; (D) sama dengan BR; (C) $K \times$ pelatihan ulang ditambah pencarian urutan; (G) tidak ada.

Metode 4 — Label Powerset (LP)

Setiap kombinasi unik dari instansi diperlakukan sebagai kelas tunggal, mengubah masalah multi-label kembali ke multi-class atas 2^K kelas. (M) sederhana secara konseptual; (D) ruang keluaran membengkak hingga $2^9 = 512$ kelas, sebagian besar tidak pernah muncul di data; (C) sangat tinggi karena *sparsity*; (G) tidak ada. **Tidak direkomendasikan** untuk $K = 9$.

Metode 5 — *Spatial prior* berbasis lokasi GPS (instansi terdekat)

Manfaatkan fakta bahwa setiap laporan Jakarta CRM membawa GPS dan setiap dinas (terutama *Suku Dinas* tingkat kotamadya) memiliki yurisdiksi spasial. Estimasi *prior spasial* dengan *Kernel Density Estimation* dari frekuensi historis laporan per kelas:

$$P(k | \ell) = \frac{P(\ell | k) P(k)}{\sum_{k'=1}^K P(\ell | k') P(k')}, \quad (2)$$

dengan $P(\ell | k)$ adalah KDE Gaussian dari lokasi-lokasi laporan historis berlabel k . Untuk *Kelurahan*, prior spasial sangat tajam karena setiap kelurahan menangani wilayah yang spesifik; untuk dinas tingkat-kota seperti *Sumber Daya Air*, prior lebih datar karena cakupan provinsi. (M) berbasis Bayes formal; (D) GPS sudah ada di setiap laporan historis; (C) rendah karena KDE bersifat *one-shot offline*; (G) tidak ada secara mandiri, tetapi memberikan informasi yang ortogonal terhadap modalitas citra dan teks. Penggunaan informasi spasial

pada sistem 311 / aduan publik telah didokumentasikan oleh [Kontokosta and Hong \(2021\)](#) dan [Cavallo et al. \(2014\)](#).

Metode 6 — Split-Conformal multi-label dengan jaminan cakupan

Lapisan kalibrasi *post-hoc* yang berdiri di atas metode dasar (1, 2, 3, atau 5). Pada subset kalibrasi $\{(x_i, Y_i)\}_{i=1}^n$ dengan label multi-label, hitung skor non-konformitas $\alpha_i = 1 - \min_{k \in Y_i} s_k(x_i)$, lalu ambil kuantil $\hat{q}_{1-\alpha} = \lceil (n+1)(1-\alpha) \rceil / n$ -quantile dari $\{\alpha_i\}$. Pada inferensi, emisikan $\hat{Y}(x) = \{k : s_k(x) \geq 1 - \hat{q}_{1-\alpha}\}$ ([Cauchois et al., 2021](#); [Vovk et al., 2005](#)). **(M)** berbasis teori conformal yang ketat; **(G)** memberikan jaminan marginal $\mathbb{P}(Y \subseteq \hat{Y}) \geq 1 - \alpha$ tanpa asumsi distribusi; **(D)** butuh subset kalibrasi multi-label kecil (~ 200 – 500 contoh); **(C)** sangat rendah.

1.4 Perbandingan Ringkas

Tabel 1: Perbandingan enam metode penanganan rute multi-instansi pada sistem klasifikasi laporan Jakarta CRM.

Metode	Dasar matematis	Data multi-label	Pelatihan ulang	Jaminan formal
1. Top-K margin	Heuristik	Tidak	Tidak	Tidak
2. Binary Relevance	Asumsi independensi	Ya	Ya ($K \times$)	Tidak
3. Classifier Chains	Korelasi antar-label	Ya	Ya ($K \times$)	Tidak
4. Label Powerset	Multi-class atas 2^K	Ya	Ya (<i>sparse</i>)	Tidak
5. Spatial prior (KDE)	Bayes	Tidak (pakai histori)	Tidak	Tidak
6. Split-Conformal multi-label	Conformal prediction	Ya (subset kalibrasi)	Tidak	$\mathbb{P}(Y \subseteq \hat{Y}) \geq 1 - \alpha$

1.5 Rekomendasi: Hybrid (Metode 5 + 2 + 6)

Tidak ada metode tunggal yang optimal pada keseluruhan empat kriteria. Yang paling kuat secara teori dan praktis adalah *kombinasi tiga lapis* yang memanfaatkan informasi ortogonal yang tersedia pada sistem Jakarta CRM:

$$s_k(x, \ell) = \underbrace{P_{\text{BR}}(y_k = 1 \mid x)}_{\text{Metode 2}} \cdot \underbrace{P(k \mid \ell)^\beta}_{\text{Metode 5}}, \quad (3)$$

dengan $\beta \in [0, 1]$ sebagai *exponent* pengontrol bobot prior spasial yang dipilih melalui validasi silang. Lapisan akhir adalah **split-conformal multi-label** (Metode 6) di atas s_k untuk memberikan ambang τ tunggal yang sah dengan jaminan cakupan marginal $1 - \alpha$.

Justifikasi matematis pemilihan kombinasi ini. Empat alasan menopang pilihan ini:

1. **Faktorisasi Bayes yang sah.** Mengasumsikan informasi citra-dan-teks x dan informasi lokasi ℓ bersifat independen secara kondisional terhadap instansi k — asumsi yang masuk akal karena x menggambarkan *isi* laporan sedangkan ℓ menggambarkan *konteks geografis* — diperoleh:

$$P(k | x, \ell) \propto P(x | k) P(\ell | k) P(k), \quad (4)$$

sejajar dengan struktur Naive Bayes lintas modalitas yang formal kerangkanya dirumuskan oleh [Lewis \(1998\)](#).

2. **Diversifikasi kesalahan (*error decorrelation*).** Modalitas citra-dan-teks dan modalitas lokasi memiliki sumber kesalahan yang berbeda; menggabungkan keduanya mengurangi varians prediksi, sebagaimana argumen ensembel oleh [Lakshminarayanan et al. \(2017\)](#).
3. **Jaminan formal *end-to-end*.** Hanya Metode 6 yang menyediakan jaminan marginal *distribution-free*, fitur yang krusial untuk sistem publik berkonsekuensi seperti perutean laporan banjir ([Angelopoulos and Bates, 2021](#)).
4. **Mengakomodasi *aleatoric noise*.** Keluaran multi-label mengakomodasi kasus di mana label "benar" memang multi-elemen (lihat analisis keterbatasan PGS pada dokumen `pgs_analysis.tex`); ini bukan *label noise* yang dapat dibersihkan, melainkan struktur masalah yang harus dimodelkan ([Hüllermeier and Waegeman, 2021](#)).

Runner-up. Apabila *ground-truth* multi-label tidak dapat diperoleh (Sub-bagian 1.6 di bawah gagal), gunakan **Metode 1 + Metode 5**: Top-K margin di-*rerank* dengan prior spasial. Tidak ada jaminan formal, tetapi tidak membutuhkan label multi-instansi.

1.6 Penanganan Keterbatasan Label Tunggal pada Dataset Historis

Dataset Jakarta CRM saat ini menyimpan satu instansi per laporan (keputusan akhir operator). Tiga jalur untuk memperoleh label multi-instansi yang dibutuhkan oleh Metode 2, 3, dan 6:

1. **Augmentasi berbasis kata kunci** (paling murah): kamus kata kunci per instansi (mis. "*berlubang*", "*aspal*" → Bina Marga; "*parkir*", "*trotoar*", "*lalu lintas*" → Perhubungan); jika ≥ 2 instansi terdeteksi, tandai sebagai multi-label.
2. **Anotasi ulang aktif (*active learning*)**: ambil laporan dengan ketidakpastian PGS tinggi (desil teratas) dan re-anotasi oleh dua anotator dengan adjudikasi.
3. **Weak supervision (Snorkel)**: gabungkan kata kunci, kata kerja tindakan, dan entitas lokasi sebagai *labelling functions* untuk menghasilkan label probabilistik multi-label ([Ratner et al., 2017](#)).

Direkomendasikan: kombinasi (1) dan (2). Jalur (1) dipakai untuk korpus pelatihan utama; jalur (2) dipakai untuk subset kalibrasi conformal yang lebih bersih, agar jaminan cakupan pada Metode 6 valid.

1.7 Perubahan API, Basis Data, dan Antarmuka Klien

Reformulasi keluaran ke himpunan label memerlukan tiga perubahan ringan pada *stack* aplikasi:

- **Endpoint** `/predict` pada `serve_model.py` diubah agar mengembalikan `predicted_dinas: List[str]` alih-alih `str`, beserta `confidence_per_dinas: Dict[str, float]` dan `routing_strategy: str` ("single", "multi-topk", atau "multi-conformal").
- **Skema basis data Supabase** menambahkan tabel pivot `report_dinas` dengan kolom (`report_id`, `dinas_id`, `confidence`) sebagai relasi *many-to-many*, menggantikan kolom tunggal `assigned_dinas` pada tabel `reports`.
- **Klien Flutter** pada `ai_result_review_screen.dart` menampilkan daftar instansi yang dirutekan beserta *confidence chip* per instansi; pengguna dapat menghapus instansi yang dianggap tidak relevan sebelum mengirim laporan.

1.8 Metrik Evaluasi Multi-Instansi

Metrik *single-label* (akurasi seimbang, macro-F1) tidak lagi memadai. Tambahan yang direkomendasikan:

- **Subset Accuracy** (*exact-match*): $\frac{1}{N} \sum_{i=1}^N \mathbb{1}[\hat{Y}_i = Y_i]$.
- **Hamming Loss**: $\frac{1}{NK} \sum_{i=1}^N \sum_{k=1}^K \mathbb{1}[\hat{y}_{ik} \neq y_{ik}]$.
- **Micro-F1 dan Macro-F1 multi-label** (Zhang and Zhou, 2014).
- **Coverage rate empiris**: $\frac{1}{N} \sum_{i=1}^N \mathbb{1}[Y_i \subseteq \hat{Y}_i]$; harus $\geq 1 - \alpha$ untuk Metode 6 sah.
- **Ukuran himpunan rata-rata**: $\mathbb{E}[|\hat{Y}|]$; diharapkan berada dalam $[1, 2]$ agar tidak membajiri operator dengan rute jamak.

Dengan kombinasi reformulasi formal (1), faktorisasi Bayes spasial-konten (4), pembobotan hibrida (3), kalibrasi conformal yang berjaminan, dan metrik evaluasi multi-label, sistem klasifikasi laporan Jakarta CRM dapat diperluas dari *single-label routing* menjadi *multi-instansi routing* yang sah secara statistik dan praktis untuk operasi pemerintah daerah.

Pustaka

Angelopoulos, A. N. and Bates, S. (2021). A gentle introduction to conformal prediction and distribution-free uncertainty quantification. *arXiv preprint arXiv:2107.07511*. Pengantar modern dan praktis ke conformal prediction termasuk varian split-conformal yang dipakai pada Metode 6.

Cauchois, M., Gupta, S., and Duchi, J. C. (2021). Knowing what you know: Valid and validated confidence sets in multiclass and multilabel prediction. *Journal of Machine Learning Research*, 22(81):1–42. Conformal prediction untuk masalah multi-class dan multi-label dengan jaminan cakupan marginal distribution-free; basis Metode 6 pada multi-instansi handling.

- Cavallo, S., Lynch, J., and Scull, P. (2014). The digital divide in citizen-initiated government contacts: A GIS approach. *Journal of Urban Affairs*, 36(1):117–146. Analisis GIS terhadap aduan warga ke pemerintah kota dan ketersediaan layanan; mendukung penggunaan informasi spasial pada perutean laporan.
- Hüllermeier, E. and Waegeman, W. (2021). Aleatoric and epistemic uncertainty in machine learning: An introduction to concepts and methods. *Machine Learning*, 110(3):457–506. Survei lengkap konsep dan metode kuantifikasi ketidakpastian aleatoric vs epistemic; landasan untuk Alasan 1 pada analisis PGS.
- Kontokosta, C. E. and Hong, B. (2021). Bias in smart city service request data: Sociospatial inequities of '311' reporting. *Environment and Planning B: Urban Analytics and City Science*, 48(7):2049–2067. Studi bias spasial pada sistem aduan publik 311 dan implikasi untuk model klasifikasi laporan; relevan dengan prior spasial pada Metode 5.
- Lakshminarayanan, B., Pritzel, A., and Blundell, C. (2017). Simple and scalable predictive uncertainty estimation using deep ensembles. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 6402–6413. Memperkenalkan deep ensembles sebagai baseline kuat untuk kuantifikasi ketidakpastian prediktif; pembandingan teoretis untuk virtual ensembles PGS pada Alasan 4.
- Lewis, D. D. (1998). Naive (bayes) at forty: The independence assumption in information retrieval. In *Proceedings of the European Conference on Machine Learning (ECML)*, pages 4–15. Springer. Tinjauan klasik atas asumsi independensi kondisional Naive Bayes; menjustifikasi faktorisasi $P(k \rightarrow x, l) \propto P(x \rightarrow k)P(l \rightarrow k)P(k)$ pada Metode 5.
- Ratner, A., Bach, S. H., Ehrenberg, H., Fries, J., Wu, S., and Ré, C. (2017). Snorkel: Rapid training data creation with weak supervision. In *Proceedings of the VLDB Endowment*, volume 11, pages 269–282. VLDB Endowment. Kerangka weak supervision untuk membangun dataset terlabel cepat dengan menggabungkan beberapa labelling functions; relevan untuk augmentasi label multi-instansi.
- Read, J., Pfahringer, B., Holmes, G., and Frank, E. (2009). Classifier chains for multi-label classification. In *Proceedings of the European Conference on Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*, pages 254–269. Springer. Memperkenalkan metode Classifier Chains yang menangkap korelasi antar-label dengan rangkaian klasifikator biner berurutan; lebih kuat daripada Binary Relevance pada label berkorelasi.
- Tsoumakas, G. and Katakis, I. (2007). Multi-label classification: An overview. *International Journal of Data Warehousing and Mining (IJDWM)*, 3(3):1–13. Survei dasar masalah klasifikasi multi-label, taksonomi metode (problem transformation vs algorithm adaptation), dan metrik evaluasi.
- Vovk, V., Gammerman, A., and Shafer, G. (2005). *Algorithmic Learning in a Random World*. Springer, New York. Buku referensi dasar conformal prediction; jaminan cakupan marginal distribution-free $P(y \in C) \geq 1 - \alpha$.

Zhang, M.-L. and Zhou, Z.-H. (2014). A review on multi-label learning algorithms. *IEEE Transactions on Knowledge and Data Engineering*, 26(8):1819–1837. Tinjauan komprehensif algoritma pembelajaran multi-label dengan formulasi formal Hamming loss, subset accuracy, micro-F1, macro-F1.