

Analisis Keterbatasan Posterior Gaussian Sampling

Standalone analysis (Deliverable 4)

1 Analisis Keterbatasan *Posterior Gaussian Sampling* pada Klasifikasi Multimodal Laporan Jakarta CRM

1.1 Latar Empiris

Hasil eksperimen pada Bab Hasil dan Pembahasan menunjukkan bahwa pengaktifan *Posterior Gaussian Sampling* (PGS) di atas kepala klasifikasi CatBoost pada arsitektur *early-fusion* multimodal hanya memberikan peningkatan moderat:

- Peningkatan *balanced accuracy* sebesar $\Delta = +0,78$ percentage point (pp).
- Peningkatan *macro-F1* sebesar $\Delta = +0,63$ pp.
- Pada modalitas citra-saja, PGS *menurunkan F1* sebesar $\Delta = -0,43$ pp.
- *Mean epistemic uncertainty* hanya $\bar{U}_{\text{epi}} = 0,00339$, yang membatasi kegunaannya sebagai sinyal *abstention*.

Bagian ini menyajikan justifikasi berbasis riset dan intuisi matematis mengapa peningkatan tersebut tidak memenuhi ekspektasi sebagai lapisan kuantifikasi ketidakpastian *end-to-end*, dengan lima alasan yang masing-masing didukung oleh literatur *peer-reviewed*.

1.2 Alasan 1 — PGS Mengukur Ketidakpastian *Epistemic*, Sedangkan Sumber Dominan adalah *Aleatoric*

PGS (Ustimenko et al., 2023) memanfaatkan ensemble virtual sebanyak $M = 30$ anggota untuk men-dekomposisi ketidakpastian total prediksi:

$$U_{\text{total}}(x) = \underbrace{H(\bar{p}(x))}_{\text{total}} = \underbrace{H(\bar{p}(x)) - \frac{1}{M} \sum_{m=1}^M H(p^{(m)}(x))}_{U_{\text{epistemic}}} + \underbrace{\frac{1}{M} \sum_{m=1}^M H(p^{(m)}(x))}_{U_{\text{aleatoric}}}, \quad (1)$$

dengan $\bar{p}(x) = \frac{1}{M} \sum_{m=1}^M p^{(m)}(x)$ sebagai *posterior mean* di atas M anggota ensemble virtual dan $H(\cdot)$ sebagai entropi Shannon. Dekomposisi ini secara formal mengikuti kerangka *aleatoric-epistemic* yang dirumuskan oleh Kendall and Gal (2017) dan disurvei oleh Hüllermeier and Waegeman (2021).

Pada dataset Jakarta CRM, sumber-sumber ketidakpastian *aleatoric* (yang melekat pada data dan tidak dapat dikurangi dengan menambah kapasitas model atau anggota ensemble) bersifat dominan:

- Pemetaan 487 nama SKPD mentah ke sembilan instansi target merupakan pemetaan *many-to-one* yang menghancurkan informasi (Sub-bab Pemetaan ke Sembilan Instansi Target).
- Keputusan perutean operator bersifat tidak konsisten lintas tahun.
- Beberapa laporan secara historis sah untuk dirutekan ke lebih dari satu instansi — yaitu kasus multi-instansi yang dibahas pada `multi_instansi_handling.tex` — sehingga label "benar" pada hakikatnya bersifat *set-valued*, bukan *point-valued*.

Ketidakpastian *aleatoric* bersifat irreducibel sebagaimana ditegaskan oleh [Kendall and Gal \(2017\)](#) dan [Hüllermeier and Waegeman \(2021\)](#). PGS yang ditujukan untuk merefinasi ketidakpastian *epistemic* dengan demikian tidak dapat membantu mengatasi komponen dominan dari ketidakpastian total pada dataset ini.

1.3 Alasan 2 — PGS Tidak Memberikan Jaminan Cakupan, Tidak Seperti *Conformal Prediction*

PGS mengembalikan *posterior mean* $\bar{p}(x)$ yang terkalibrasi secara konstruktif terhadap keluarga ensemble virtual; namun PGS tidak menawarkan jaminan formal apapun bahwa himpunan prediksi top-1 mencapai probabilitas cakupan yang ditentukan sebelumnya $1 - \alpha$. Hal ini merupakan perbedaan struktural dari *conformal prediction* (CP), yang menghasilkan himpunan prediksi $\hat{C}_\alpha(x)$ yang memenuhi:

$$\mathbb{P}(y \in \hat{C}_\alpha(x)) \geq 1 - \alpha \quad (2)$$

secara marginal pada distribusi data yang dapat dipertukarkan (*exchangeable*), tanpa asumsi distribusi parametrik ([Vovk et al., 2005](#); [Angelopoulos and Bates, 2021](#)).

Untuk sistem keputusan hilir yang harus *merutekan atau mengeskalasi* laporan, kuantitas yang penting bagi operator adalah "berapa sering instansi yang benar berada dalam himpunan top-K?" — yaitu kuantitas cakupan. Skalar ketidakpastian *epistemic* PGS (mean $\bar{U}_{\text{epi}} = 0,00339$ pada eksperimen ini) tidak dapat diterjemahkan secara langsung menjadi cakupan tersebut; operator masih harus memilih ambang secara *ad hoc* tanpa dukungan statistik formal. Akibatnya, PGS tidak dapat dimanfaatkan sebagai dasar lapisan *selective prediction* dengan jaminan risiko ([Geifman and El-Yaniv, 2017](#); [El-Yaniv and Wiener, 2010](#)).

1.4 Alasan 3 — PGS Mengasumsikan *Base Learner* Sudah Terkalibrasi; CatBoost pada Multi-Class 9-Kelas Tidak

PGS adalah refinasi *post-hoc* yang menghitung *posterior mean* di atas sampel ensemble; jika keluaran *softmax* per anggota ensemble sendiri belum terkalibrasi, rata-rata mereka tidak akan memperbaiki bias tersebut. [Guo et al. \(2017\)](#) menunjukkan bahwa klasifikator modern berkapasitas tinggi cenderung *overconfident* dan membutuhkan kalibrasi suhu (*temperature scaling*) eksplisit. [Niculescu-Mizil and Caruana \(2005\)](#) menunjukkan secara empiris bahwa metode *boosted trees* (kelompok yang menaungi CatBoost) cenderung memberikan probabilitas yang *sigmoid-distorted*: terlalu yakin pada kelas mayoritas dan terlalu konservatif pada kelas minoritas, dan membutuhkan *Platt scaling* atau *isotonic regression* untuk kalibrasi yang sah.

Observasi empiris bahwa PGS *menurunkan* F1 pada modalitas citra-saja sebesar $\Delta = -0,43$ pp konsisten dengan teori ini: ketika kepala CatBoost unimodal kurang terkalibrasi (kemungkinan karena *embedding* DINOv3-large secara mandiri tidak cukup memisahkan kelas-kelas yang terkait konteks seperti *Dinas Sosial* versus *Dinas Lingkungan Hidup*), rata-rata ensembel virtual justru memperkuat bias yang sudah ada alih-alih memperbaikinya.

1.5 Alasan 4 — Ensembel Virtual Berbagi Parameter, sehingga PGS Meremehkan Sebaran *Epistemic* yang Sebenarnya

Sebanyak $M = 30$ anggota ensembel virtual pada PGS bukanlah model independen yang dilatih secara terpisah; mereka adalah sub-pohon dari *satu* model CatBoost yang disampling melalui prosedur bertipe *Stochastic Gradient Langevin Dynamics* (Ustimenko et al., 2023). Sebaliknya, *deep ensembles* sejati (Lakshminarayanan et al., 2017) melatih M model independen dari *random initialisation* yang berbeda dan secara konsisten mengungguli proksi ketidakpastian model-tunggal pada *benchmark* klasifikasi.

Secara matematis, varians prediksi dari ensembel-berbagi-parameter σ_{shared}^2 memiliki batas atas yang lebih kecil dibandingkan varians ensembel independen σ_{indep}^2 karena korelasi residual antar-anggota $\rho > 0$:

$$\sigma_{\text{shared}}^2 = \frac{1}{M} [(1 - \rho)\sigma^2 + M\rho\sigma^2] \xrightarrow{M \rightarrow \infty} \rho\sigma^2 < \sigma^2 = \sigma_{\text{indep}}^2. \quad (3)$$

PGS *men-trade* kekuatan statistik tersebut untuk efisiensi inferensi — pilihan rekayasa yang disengaja pada CatBoost — tetapi konsekuensinya, sebaran *epistemic* yang dilaporkan PGS bias rendah. Hal ini konsisten dengan observasi mean ketidakpastian yang sangat kecil pada eksperimen ini ($\bar{U}_{\text{epi}} = 0,00339$), yang membatasi sinyal untuk *selectivity* atau *abstention* hilir.

1.6 Alasan 5 — Sistem Hilir Mengelaminasi Sinyal Ketidakpastian melalui *argmax* Tunggal

Sekalipun PGS menghasilkan estimasi ketidakpastian yang sempurna, sistem yang *deployed* mengembalikan kembali prediksi ke satu label tunggal melalui `np.argmax(probs)` pada `serve_model.py`. Klien Flutter kemudian hanya menampilkan ketidakpastian sebagai persentase kepercayaan pada layar hasil, bukan sebagai aksi *abstention* maupun perutean ke beberapa instansi. Akibatnya, *manfaat praktis* PGS dibatasi oleh apa yang dilakukan antarmuka pengguna terhadap skalar tersebut — dan saat ini tidak dilakukan apa-apa secara operasional.

Perbaikan yang sah secara teori adalah lapisan *selective prediction* dengan ambang yang berjaminan cakupan (Geifman and El-Yaniv, 2017; El-Yaniv and Wiener, 2010) atau keluaran himpunan-bernilai (*set-valued*) melalui *conformal prediction* (Angelopoulos and Bates, 2021; Vovk et al., 2005). Hubungan langsung dengan jalur ekstensi *multi-instansi routing* dijelaskan pada dokumen `multi_instansi_handling.tex`, khususnya pada Metode 6 (*split-conformal multi-label*).

1.7 Rekomendasi Penutup

Berdasarkan lima alasan di atas, narasi PGS pada bab Hasil dan Pembahasan sebaiknya direvisi dari "PGS memberikan peningkatan kecil namun positif" menjadi narasi yang lebih

utuh sebagai berikut:

PGS memberikan kuantifikasi ketidakpastian epistemic dengan biaya inferensi yang nyaris nol; namun pada dataset Jakarta CRM ini (i) ketidakpastian aleatoric bersifat dominan dan irreducibel oleh ensemble virtual, (ii) sistem tidak memiliki lapisan selective prediction yang berjaminan cakupan, (iii) base learner CatBoost pada modalitas unimodal belum sepenuhnya terkalibrasi, (iv) ensemble virtual berbagi parameter sehingga sebaran epistemic yang dilaporkan bias rendah, dan (v) antarmuka single-argmax pada lapisan sistem hilir tidak memanfaatkan sinyal ketidakpastian secara operasional. Iterasi mendatang sebaiknya menggantikan PGS dengan split-conformal prediction di atas embedding hasil fusi awal untuk memperoleh rekomendasi perutean himpunan-bernilai dengan jaminan cakupan marginal yang dapat dibuktikan, sebagaimana diuraikan pada dokumen `multi_instansi_handling.tex`.

Dengan reposisi ini, PGS bukan dipandang sebagai *kegagalan*, melainkan sebagai *lapisan ketidakpastian yang berbiaya rendah* yang baik sebagai *baseline* namun perlu dilengkapi — bukan digantikan begitu saja — oleh kerangka kalibrasi yang berjaminan cakupan untuk mencapai keandalan *end-to-end* pada sistem layanan publik.

Pustaka

- Angelopoulos, A. N. and Bates, S. (2021). A gentle introduction to conformal prediction and distribution-free uncertainty quantification. *arXiv preprint arXiv:2107.07511*. Pengantar modern dan praktis ke conformal prediction termasuk varian split-conformal yang dipakai pada Metode 6.
- El-Yaniv, R. and Wiener, Y. (2010). On the foundations of noise-free selective classification. *Journal of Machine Learning Research*, 11(53):1605–1641. Landasan teoretis selective classification dengan formulasi risk-coverage trade-off.
- Geifman, Y. and El-Yaniv, R. (2017). Selective classification for deep neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 4878–4887. Selective prediction untuk deep neural networks dengan jaminan risk-coverage; landasan Alasan 5 pada analisis PGS.
- Guo, C., Pleiss, G., Sun, Y., and Weinberger, K. Q. (2017). On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, volume 70, pages 1321–1330. PMLR. Menunjukkan bahwa klasifikator modern berkapasitas tinggi cenderung overconfident dan mengusulkan temperature scaling sebagai metode kalibrasi sederhana; landasan Alasan 3 pada analisis PGS.
- Hüllermeier, E. and Waegeman, W. (2021). Aleatoric and epistemic uncertainty in machine learning: An introduction to concepts and methods. *Machine Learning*, 110(3):457–506. Survei lengkap konsep dan metode kuantifikasi ketidakpastian aleatoric vs epistemic; landasan untuk Alasan 1 pada analisis PGS.
- Kendall, A. and Gal, Y. (2017). What uncertainties do we need in Bayesian deep learning for computer vision? In *Advances in Neural Information Processing Systems (NeurIPS)*,

volume 30, pages 5574–5584. Memformalkan dekomposisi ketidakpastian aleatoric (data-inherent) vs epistemic (model-inherent) pada deep learning; landasan teori Alasan 1 pada analisis PGS.

Lakshminarayanan, B., Pritzel, A., and Blundell, C. (2017). Simple and scalable predictive uncertainty estimation using deep ensembles. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 6402–6413. Memperkenalkan deep ensembles sebagai baseline kuat untuk kuantifikasi ketidakpastian prediktif; pembandingan teoretis untuk virtual ensembles PGS pada Alasan 4.

Niculescu-Mizil, A. and Caruana, R. (2005). Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, pages 625–632. ACM. Studi empiris kalibrasi probabilitas pada berbagai metode supervised learning; menunjukkan boosted trees memiliki distorsi sigmoid dan butuh Platt/isotonic scaling.

Ustimenko, A., Beliakov, A., and Prokhorenkova, L. (2023). Uncertainty estimation in CatBoost: Virtual Ensembles and Posterior Sampling.

Vovk, V., Gammerman, A., and Shafer, G. (2005). *Algorithmic Learning in a Random World*. Springer, New York. Buku referensi dasar conformal prediction; jaminan cakupan marginal distribution-free $P(y \in C) \geq 1 - \alpha$.